데이터분석을위한 PANDAS

PANDAS PROGRAMMING

PANDAS 데이터 이해

PANDAS 데이터 이해

◆ 데이터 정보 확인

- 전체 데이터 구조 확인
- 열 단위 데이터의 산술 통계 값 확인
- 데이터의 형태, 크기(개수) 확인
- 데이터 분석을 위한 기초 정확 수집

PANDAS 데이터 이해

◆ 데이터 정보 확인

- **정보 함수**

앞부분 데이터 보기	: DataFrame 객체. **head (n) 기본 5개**
뒷부분 데이터 보기	: DataFrame 객체. **tail (n)**
데이터 기본 정보 보기	: DataFrame 객체. **info()**
데이터 기술 통계정보	: DataFrame 객체. **describe()**
데이터 기술 통계정보	: DataFrame 객체. **describe(include ='all')**

PANDAS 데이터 이해

◆ 데이터 정보 확인

▪ 데이터 개수 함수

각 열 데이터 개수 반환 : DataFrame 객체**.count()**

고유값 종류별 개수 반환 : DataFrame객체['열이름']**. value_counts()**

→ 옵션 : dropna = False (기본값)

결측치(Missing value , NaN) 포함 여부

PANDAS 데이터 이해

◆ 데이터 정보 확인

▪ 통계 개념

편차 (Deviation)

관측값에서 평균(mean)을 뺀 값, 평균에서 얼마나 떨어진 값인지 확인

분산(Variance)

평균(mean)에서 얼만큼 벗어나 있는가를 나타내는 값 , 편차를 제곱한 값

표준편차(standard deviation)

분산 값에 루트를 씌운 값

◆ 데이터 정보 확인

▪ 통계 개념

값 사이 연관성 & 분포 여부

A **1, 3, 5, 7, 9**

편차	-4	-2	0	2	4
편차의 제곱	16	4	0	4	16

분산 (편차의 제곱의 평균) $(16+4+0+4+16) \div 5 = 8$

표준 편차 (분산의 제곱근) $\sqrt{8}$

B **3, 4, 5, 6, 7**

편차	-2	-1	0	1	2
편차의 제곱	4	1	0	1	4

분산 (편차의 제곱의 평균) $(4+1+0+1+4) \div 5 = 2$

표준 편차 (분산의 제곱근) $\sqrt{2}$

◆ 데이터 정보 확인

▪ 통계 개념

평균 (mean)

모든 관측값의 합을 자료의 개수로 나눈 값

중앙(간)값(median)

전체 관측값을 크기 순서로 정렬했을 때 가운데 위치한 값

홀수 경우: (n+1) /2 번째

짝수 경우: (n/2)번째 관측값과 (n+1) /2번째 관측값의 평균

최빈값 (mode)

데이터 중 가장 많은 빈도로 나타나는 값

PANDAS 데이터 이해

◆ 데이터 정보 확인

- 통계 개념 --- 값 분포

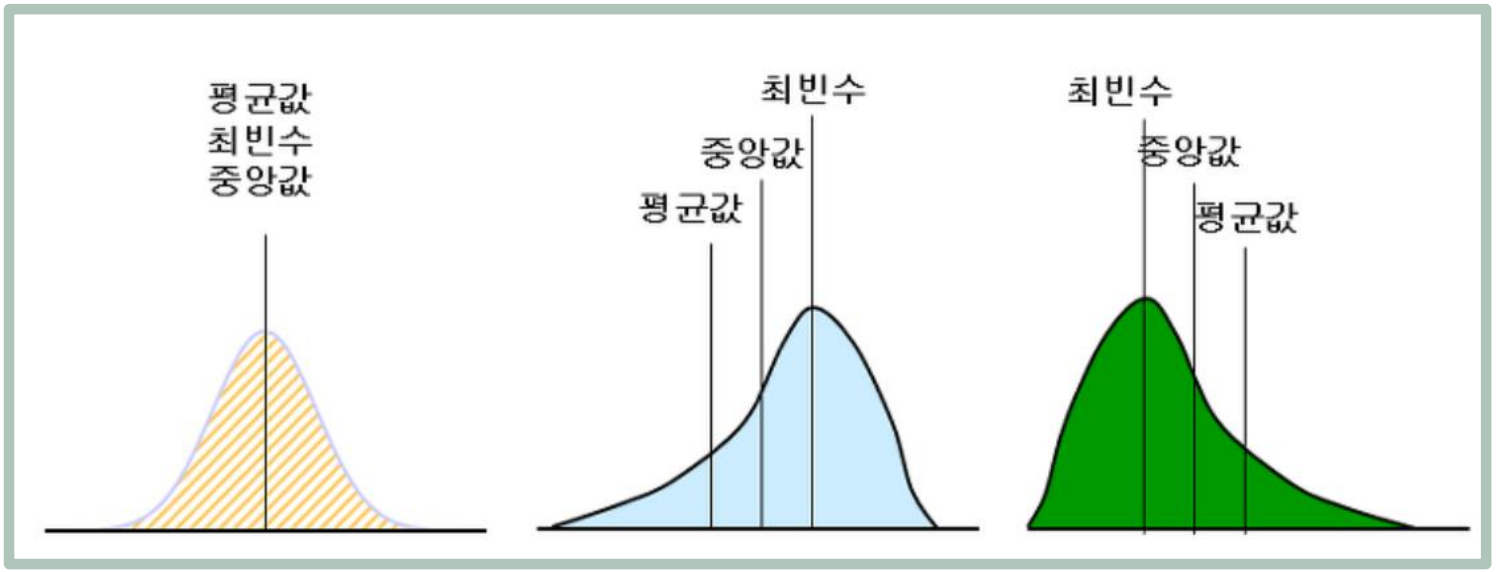

◆ 데이터 정보 확인

▪ 통계 개념 – 값들의 관계

상관계수(correlation coefficient)

두 열(column) 사이 관계 정도를 나타내는 수치

- 범위 : -1 ~ 1 사이
- -1(음의 상관관계), 1(양의 상관관계)에 가까울 수록 관계 밀접

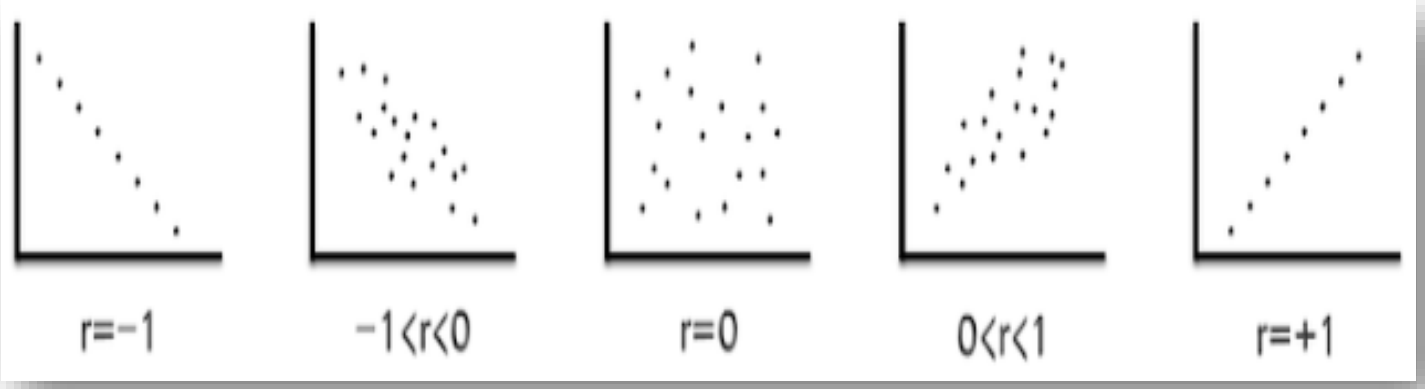

PANDAS 데이터 이해

◆ 데이터 정보 확인

- **통계 함수**

모든 열 평균값 = DataFrame 객체.**mean()**
특정 열 평균값 = DataFrame 객체**['열이름']. mean()**

모든 열 중간값 = DataFrame 객체.**median()**
특정 열 중간값 = DataFrame 객체**['열이름']. median()**

모든 열 최대값 = DataFrame 객체.**max()**
특정 열 최대값 = DataFrame 객체**['열이름']. max()**

모든 열 최소값 = DataFrame 객체.**min()**
특정 열 최소값 = DataFrame 객체**['열이름']. min()**

PANDAS 데이터 확인

◆ 데이터 정보 확인

- **통계 함수**

모든 열 표준편차 = DataFrame 객체.**std()**

특정 열 표준편차 = DataFrame 객체**['열이름'].std()**

모든 열 상관계수 = DataFrame 객체.**corr()**

특정 열 상관계수 = DataFrame 객체**['열이름'].corr()**

PANDAS 데이터 이해

◆ 데이터 정보 확인

▪ 통계 개념

결측값(Missing Value)

입력되지 않은 값

- 표기 : NaN
- 사용 : 분석에서 제거 & 다른 값 치환

특이값(Outlier)

정상적인 데이터 분포 범위 박에 존재하는 값

- 논리적으로 존재할 수 없는 값 (예: 나이 -7, 1002)

PANDAS 데이터 분류

◆ 데이터 분류

- 데이터 분석의 제일 먼저 진행되어야 하는 분류
- 데이터 종류에 따른 분석 방법 설정

특성에 따른 분류

변수 개수에 따른 분류

PANDAS 데이터 분류

◆ 데이터 분류

▪ 특성에 따른 분류

범주형 (Categorical)	- 질적 (qualitative data , 정성적 자료) 라고도 함 - 수치로 측정 불가능한 자료 - 성별, 혈액형, 종교, 순위 등 범주/그룹으로 구분 가능 데이터
연속형 (Numerical)	- 양적 (quantitative data , 정량적 자료) 라고도 함 - 수치로 측정 가능한 자료 - 온도, 가격, 주가지수, 실업률, 매출액, 키 등 숫자로 구성 - 대소, 평균, 최댓값, 최솟값 등 산술연산 분석 가능 데이터

PANDAS 데이터 분류

◆ 데이터 분류

▪ 변수에 따른 분류

변수 (Variable Data)	- 연구・조사・관찰하고 싶은 대상 - 예)키, 몸무게, 혈액형, 매출액, 습도, 먼지 농도 등등....
단일변수 자료 (Univariate Data)	- 변수가 **1개로만 구성된 자료** - **일변량 자료**라고도 함
다중변수 자료 (Multivariate Data)	- 변수가 **2개 이상으로 구성된 자료** - **다변량 자료**라도도 함